



113 學年度專題成果報告

專題名稱：運用深度學習的方法分析傷口類型

組員：

姓名	學號
黃妤涵	411770349
吳佩婷	411770109
溫苡均	411770281
李佩臻	411770547

班別：AI三B

指導老師：鄧有光、林先彥 教授

中華民國 114 年 6 月

目錄

一、動機與目的	2
二、相關文獻	2
2.1 壓瘡介紹	2
2.2.1 EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks[2]	3
2.2.2 ResNet: Deep Residual Learning for Image Recognition[3]	3
2.3 影像重建	4
2.4 Ordinal classification	4
2.5 Multi-Task	4
2.6 濾波器激勵視覺化	5
三、資料集與預處理	5
四、模型與方法比較	6
4.1 一般分類	6
4.1.1 EfficientNet	7
4.1.2 ResNet	8
4.2 影像重建	10
4.2.1 EfficientNet	11
4.2.2 ResNet	13
4.3 Ordinal Classification	14
4.4 Multi-task	16
五、資料視覺化	19
5.1 濾波器激活視覺化	19
5.2 剪枝	20
5.3 分類關注區域	21
六、結果與討論	23
七、未來發展方向	24
八、資料來源	24

一、動機與目的

在臨床傷口診斷中,目前已有許多研究聚焦於不同傷口類型之間的分類,例如壓瘡與糖尿病足潰瘍等,然而我們觀察到,相較於跨類型的傷口辨識,同類傷口(如同為壓瘡但處於不同分級)之間的區分更具挑戰性,因為它們在外觀上可能僅有細微差異,而壓瘡根據其嚴重程度被劃分為第1至第4級,各級之間的判斷對治療決策至關重要。本研究專注於壓瘡分類,旨在評估並找出最適合進行壓瘡分級的深度學習模型,期望提升分類準確率與臨床判讀一致性,進而協助診斷與提升醫療效率。

二、相關文獻

2.1 壓瘡介紹

○ Pressure Ulcers: Prevention, Evaluation, and Management[1]

- 本篇論文主要探討了壓瘡傷口其主要形成原因與分級方法與預防措施等等問題。
- 定義與成因:壓瘡(褥瘡)通常發生在骨隆起部位,主要因長時間受壓導致血液循環受阻,組織缺氧壞死。內在因素:行動受限、營養不良、皮膚老化、慢性疾病等。外在因素:壓力、摩擦力、剪切力等。
- 常見發生部位:骯骨、足跟、坐骨結節、大轉子、外踝。
- 預防措施:
 - 風險評估:使用 Braden 量表等工具。
 - 減壓措施:
 - 定期翻身(每2小時一次)
 - 使用減壓裝置(壓力 < 32 mmHg)
 - 降低床頭角度,避免剪切力
- 壓瘡分級:依傷口大小、壞死組織、滲出物、感染情況等,將壓瘡分為四級:
 - 第一期:皮膚完整,局部不可回復性紅斑,可能伴隨疼痛、變硬、變軟、溫度異常。
 - 第二期:部分皮層喪失,呈現淺層開放性潰瘍或漿液性水泡,無壞死組織。
 - 第三期:全層組織喪失,傷口可能有壞死組織(slough),但不會暴露骨骼、肌腱或肌肉,可見邊緣破壞或隧道現象。
 - 第四期:全層組織喪失,並暴露骨骼、肌腱或肌肉,伴隨壞死組織、焦痂、隧道現象或邊緣破壞。
 - 無法分期:傷口有壞死組織,無法確定深度。
- 醫學評估與傷口檢查:
 - 病史調查:發生時間、過去治療方式、合併症、用藥情況、心理與行為狀態。
 - 傷口檢查:

- 記錄數量、位置、大小(長度、寬度、深度)。
- 觀察滲出液、氣味、壞死組織、焦痂(eschar)。
- 評估是否有隧道現象(tunneling)、邊緣破壞(undermining)、感染情形。
- 確認癒合跡象(肉芽組織形成、上皮化)。

■ 併發症:

- 非感染性併發症:異位性骨形成、假性動脈瘤、癌變潰瘍。
- 感染性併發症:菌血症、敗血症、蜂窩組織炎、骨髓炎、化膿性關節炎。

2.2 一般分類模型

2.2.1 EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks[2]

- 模型特色:傳統 CNN 模型擴展(scaling)方式多著重於單一維度的放大,如加深層數或增加通道數等,但這些方法可能提升效果有限,卻造成運算資源的浪費。該模型提出一種稱為 Compund Scaling 的方法,能透過一組固定的比例係數同時調整深度、寬度與解析度,使模型在維持運算效率的同時,能有更好的成果。
- 模型架構:基礎模型以 NAS 所生成,使用的搜尋空間與 MnasNet 相同,目標為同時最佳化模型準確率與 FLOPS。整體架構可劃分為多個階層,每個階層含有多個相同配置的 MBConv 模組(含倒置瓶頸結構、深度可分離卷積、線性激勵函數、殘差連接與 squeeze-and-excitation 模組),神經網路在每個階層逐步降低解析度並增加通道數,並根據可用資源等比增加網路深度、寬度與解析度,確保可在不同資源下都能取得最優組合。
- 訓練結果:EfficientNet-B7 在 ImageNet 上達到 8.43% 的 Top-1 Acc,且參數量減少 8.4 倍,速度提升 6.1 倍。在 CIFAR-100、Flowers、Stanford Cars 等資料集也展現優秀的泛化能力。

2.2.2 ResNet: Deep Residual Learning for Image Recognition[3]

- 模型特色:針對模型訓練隨著層數增加,誤差不降反升的問題,提出殘差學習框架,透過每兩層間加入 shortcut identity mapping 使神經網路學習的是輸入與期望輸出之間的殘差,這種方法能有效提升模型深度與訓練的穩定性。
- 模型架構:Resnet 主要由殘差模組組成,其中包含兩種設計:第一個部分為基本殘差塊,主要用於較淺層的模型(Resnet-18、Resnet-32),由兩個 3*3 連續卷積層與一個 shortcut 組成;瓶頸結構的部分則用於較深層的模型(Resnet-50、Resnet-101)由 $1*1 \rightarrow 3*3 \rightarrow 1*1$ 的卷積層所組成,能有效控制運算量與複雜度。
- 訓練結果:Resnet-152 在 ImageNet 上的 top-1 err. 為 19.38,超越當時所有單一模型與集成模型,且在 ILSVRC 2015 多項任務中獲得第一名。

2.3 影像重建

- Real-ESRGAN: Training Real-World Blind Super-Resolution with Pure Synthetic Data[4]
 - 模型特色:針對積現實世界影像的 blind super-resolution 進行處理,設計可以以純合成資料進行訓練的生成式架構,其核心創新為高階降質模擬流程,相較於傳統方式單一模糊或壓縮,REAL-ESRGAN 以多階段依序套用隨機模糊、縮放、雜訊與 JPEG 壓縮,且刻意模擬 artifact,更貼近現實攝影情況。
 - 模型架構:使用改良自 ESRGAN 的 RRDB 生成器,並引入具備頻譜正規化(spectral normalization)的 U-Net 判別器,以穩定對抗訓練並提升感知品質,訓練結合像素損失、感知損失與對抗損失進行端對端優化,模型不依賴額外的降質參數估計,即能直接從未知降質的 LR 影像中還原高品質圖像。

2.4 Ordinal classification

- dlordinal: a Python package for deep ordinal classification[5]
 - 序列分類(ordinal classification)是一種考慮類別間順序關係的監督式學習方法,常見於醫療領域,如腫瘤或糖尿病視網膜病變的分級診斷。其目標是最小化預測錯誤的嚴重程度,避免將樣本誤判為相差過遠的類別。目前雖有部分工具支援序列分類,但多數缺乏完整架構或深度學習整合。為此開發了基於 PyTorch 的 Python 套件 dlordinal,整合多種序列方法與評估工具,協助研究者有效開發與測試序列分類模型。
 - dataset:本論文當中使用兩個資料集,其中 FGNet 涵蓋不同年齡層的臉部影像,而 Adience 包含來自各種來源、未經篩選的臉部照片,適合用於開發具魯棒性的年齡與性別預測模型。
 - 重要模組:引入混合型 dropout 方法,強化對排序貢獻較大的神經元以提升模型表現;實作多種先進序列輸出層,包括累積連結模型(CLM)、stick-breaking 策略及序列二元分解(OBD)方法,有效保留標籤順序資訊;採用多種機率分布生成軟標籤,替代傳統 one-hot 標籤;整合多種序列專用 Loss,如基於軟標籤的正則化交叉熵、加權卡帕損失及 OBD 的均方誤差損失,準確反映序列誤差。
 - 評估指標:提供多種序列評估指標,如 1-off accuracy、平均與最大平均絕對誤差(AMAE、MMAE)、二次加權卡帕(QWK)、排名機率分數(RPS)及聚焦極端類別的幾何平均靈敏度(GMSEC),全面衡量模型在序列任務上的表現
 - 訓練結果:實驗結果顯示,不同方法在三個資料集上的表現因資料特性和評估指標而異。Adience 資料集中,三角分布在 MAE(0.335)與 CCR(0.753)表現優異,Beta 在 QWK(0.924)最佳;FGNet 中 CLMWK 在 QWK(0.846)領先,三角分布在 MAE(0.491)和 CCR(0.594)較佳。

2.5 Multi-Task

- Multi-Task Learning as Multi-Objective Optimization[6]:

- 傳統 MLT 的架構中,有兩種實作參數共享方式,第一個方法是設計一個參數化的假設類,讓不同的任務共享部分參數,並且這些參數是透過解一個最佳化問題而學習到,但此方法有一個具致命的缺點便是,參數只有在對所有任務都有良好效果實才成立,使得任務之間必須不能互相衝,這是現實中難以實現的理想化設計。第二個便是此篇論文所使用的方式,目標是尋找不被其他解支配的解,這些解稱為帕累托最優解,其中多梯度下降法(MDGA),是利用梯度資訊進行最佳化,其非常適合應用於深度神經網路,因為可以藉由每個任務梯度,去尋求最佳解。但此技術也有幾個缺點便是:1. 梯度維度過大,難以處理。2. 每次倒傳遞都需要對每個任務獨立計算梯度,導致運算成本過高。因此,本篇論文提出基於 Frank-Wolfe 法的最佳化器,其原理是利用上界近似的方式,使原先需要對每個任務獨立梯度計算的問題,可用單次反向傳遞解決。
- 上界近似:
相較於原本 MGDA 的方法是去尋找一組權重使得其對每個任務梯度的加權總合最小,使得要最佳化參數就必須對每個梯度執行獨立的倒傳遞,十分耗時。而上界近似則是,將所有任務的梯度方向疊加成一個合成方向,使得只需要單次倒傳遞就能取得更新方向,更省略了找尋最小加權組合這步驟,且已證明其效果和 MGDA 相同。

2.6 濾波器激勵視覺化

- Feature Visualization-How neural networks build up their understanding of images[7]
 - 定義與目標:特徵視覺化是一種觀察神經網路中某些神經元或層到底學到了什麼技術,主要目的在於幫助人類理解模型「為什麼做出這樣的決策」與「中間特徵的演變過程」
 - Activation Maximization:投過梯度上升來生成圖片,能最大化特定神經元的輸出。這張圖片可讓我們理解該神經元偏好什麼樣的輸入特徵,也是在我們的專題中主要採用的方式。
 - 實作方式:從隨機雜訊開始,透過反向傳播優化輸入圖像
 - 正規化技巧:如抖動(jitter)、平滑、剪裁、頻率懲罰等,用來讓圖像更自然、更具語意。
 - Activation Atlases:結合多張輸入圖像在網路中激活的結果,使用降維方法(如 t-SNE)生成特徵圖譜。這讓我們能直觀看到特徵空間中神經元如何排列與群聚。
 - 網路層次中的變化
深度神經網路的層越深,學到的特徵越抽象
 - 淺層:擷取邊緣、顏色等基礎特徵。
 - 中層:學習局部結構,如紋理、形狀。
 - 深層:學到物體、概念級的語意特徵,如人臉、動物、物件輪廓。

三、資料集與預處理

- 資料集:

- 來源為 Roboflow 上的兩個公開資料集,兩者皆為壓瘡傷口之照片,我們將資料集整理後將其各分為四個類別:Stage1、Stage2、Stage3、Stage4,照片數量如下表 1 所示:

	Image Size	Stage 1	Stage 2	Stage 3	Stage 4	SUM
Roboflow1	640 * 640	468	419	503	464	1854
Roboflow2	640 * 640	219	138	392	421	1170
SUM		687	557	895	885	3024

表 1

- 預處理:由表 1 可發現,各等級的壓瘡照片數量分布不均,若直接進行模型訓練,容易造成模型偏向樣本數較多的類別,影響整體分類效能。因此在訓練前,我們進行了資料前處理,確保模型能在平衡的資料下學習各類別的特徵。首先,我們先將原始資料依照 7:2:1 的比例分成訓練集、驗證集與測試集。這樣做的目的是為了避免若先擴增再切分資料,導致訓練集與測試集中出現大量重複圖片,進而影響模型的評估準確性。接著針對各資料集分別進行影像擴增,使每個等級在訓練集達到 350 張、驗證集達到 100 張、測試集達到 50 張,達成類別之間的數量平衡。擴增方法包括旋轉、水平翻轉、亮度調整、對比度強化等方式,以模擬更多元的影像情境,提升模型在實際應用上的穩定性與辨識能力。最後,將所有影像統一縮放(resize)為 224*224 像素,以符合常見卷積神經網路模型(如 ResNet、EfficientNet)的輸入尺寸,利於後續模型訓練與預測流程的進行。

四、模型與方法比較

4.1 一般分類

- 我們將兩個原始資料集使用 ResNet 及 EfficientNet 進行壓瘡 1~4 級的傷口分類,分別將模型訓練前、後兩個資料集的訓練集與測試集進行 PCA,分析模型訓練對資料分布情況的影響,圖 1 及圖 2 為 Roboflow1 訓練集與測試集原始資料呈現;圖 3 及圖 4 則是 Roboflow2 的訓練集、測試集原始資料呈現。




圖 1




圖 2




圖 3




圖 4

4.1.1 EfficientNet

- 表 2 為使用 EfficientNet 模型分別對 Roboflow1 及 Roboflow2 兩個資料集做訓練的 Accuracy 與 F1-Score。

	Stage 1	Stage 2	Stage 3	Stage 4	Accuracy	F1-Score
Roboflow1	0.23	0.35	0.34	0.29	0.3100	0.3040
Roboflow2	0.91	0.83	0.80	0.91	0.8611	0.8643

表 2

- 模型的 Loss 與 Accuracy 趨勢圖如下,圖 5 與圖 6 為 Roboflow1 的趨勢圖;圖 7 與圖 8 為 Roboflow2 的趨勢圖。




圖 5




圖 6




圖 7




圖 8

- 模型的權重圖如下,整體神經的權重呈正態分布,沒有異常值或極端值,且皆在正負 0.5 之間,由此可見我們的模型神經是健康的(有正確的學習)。圖 9 及圖 10 為對 Roboflow1 資料集的分析成果,圖 9 為整個模型的權重分佈圖,圖 10 則為對模型最後一層進行分析的結果;圖 11 及圖 12 為對 Roboflow2 資料集的分析成果,圖 11 為整個模型的權重分佈圖,圖 12 則為對模型最後一層進行分析的結果。




圖 9




圖 10




圖 11




圖 12

- 下圖為訓練後再對資料進行 PCA 分析,可以看到相較於 Roboflow1,Roboflow2 具有較佳的成果(將類別稍微分開);圖 13 及圖 14 為對 Roboflow1 的訓練集與測試集進行分析;圖 15 及圖 16 為對 Roboflow2 的訓練集與測試集進行分析。




圖 13




圖 14




圖 15




圖 16

4.1.2 ResNet

- 表 3 為使用 ResNet 模型分別對 Roboflow1 及 Roboflow2 兩個資料集做訓練的 Accuracy 與 F1-Score。

	Stage 1	Stage 2	Stage 3	Stage 4	Accuracy	F1-Score
Roboflow1	0.20	0.38	0.14	0.24	0.2500	0.2381
Roboflow2	0.86	0.67	0.55	0.75	0.7130	0.7072

表 3

- 模型的 Loss 與 Accuracy 趨勢圖如下,圖 17 與圖 18 為 Roboflow1 的趨勢圖;圖 19 及圖 20 為 Roboflow2 的趨勢圖。




圖 17




圖 18




圖 19




圖 20

- 模型的權重圖如下,整體神經的權重呈正態分布,沒有異常值或極端值,且皆在正負 0.5 之間,由此可見我們的模型神經是健康的(有正確的學習)。圖 21 及圖 22 為對 Roboflow1 資料集的分析成果,圖 21 為整個模型的權重分佈圖,圖 22 則為對模型最後一層進行分析的結果;圖 23 及圖 24 為對 Roboflow2 資料集的分析成果,圖 23 為整個模型的權重分佈圖,圖 24 則為對模型最後一層進行分析的結果。




圖 21




圖 22




圖 23




圖 24

- 下圖為訓練後再對資料進行 PCA 分析,可以看到相較於 Roboflow1,Roboflow2 具有較佳成果(將類別稍微分開),但與 EfficientNet 相比效果沒那麼好,類別間重疊的部分較多;圖 25 及圖 26 為 Roboflow1 的

訓練集、測試集進行分析;圖 27 及圖 28 為對 Roboflow2 的訓練集、測試集進行分析




圖 25




圖 26




圖 27




圖 28

4.2 影像重建

- 原始照片有些解析度過低導致模型無法學習到傷口的細節,因此使用 Real-ESRGAN 重建照片希望能使細節處可以更加清楚,重建後的圖片放大為 896*896。下圖 29 為原始照片,圖 30 為重建後的照片,可以發現中間下方傷口邊緣及組織部分有更清楚。



圖 29




圖 30

- 同樣將重建後照片的資料集分別進行 PCA 分析觀察各類別的分布位置,圖 31、32 為 Roboflow1 的訓練集、測試集呈現;圖 33、34 則是 Roboflow2 的訓練集、測試集呈現




圖 31




圖 32




圖 33




圖 34

4.2.1 EfficientNet

- 表 4 為使用 EfficientNet 模型分別對重建過後的 Roboflow1 及 Roboflow2 兩個資料集做訓練的 F1-Score 結果,然而相較於重建前的資料集,這個部分並未獲得較佳的結果。

	Stage 1	Stage 2	Stage 3	Stage 4	Accuracy	F1-Score
Roboflow1	0.21	0.21	0.46	0.35	0.3300	0.3088
Roboflow2	0.85	0.78	0.75	0.93	0.8241	0.8287

表 4

- 模型的 Loss 與 Accuracy 趨勢圖如下,圖 35、36 為對 Roboflow1 的趨勢圖;圖 37、38 為對 Roboflow2 的趨勢圖




圖 35




圖 36




圖 37




圖 38

- 模型的權重圖如下,由此可發現我們的模型是健康的。圖 39、40 為對 Roboflow1 資料集的分析成果,圖 39 為整個模型的權重圖,圖 40 為對最後一層進行分析的結果;圖 41、42 為對 Roboflow2 資料集的分析成果,圖 41 為整個模型的權重圖,圖 42 為對最後一層進行分析的結果




圖 39




圖 40




圖 41




圖 42

- 下圖為訓練後再對資料進行 PCA 分析,可以看到相較於 Roboflow1, Roboflow2 具有較佳成果(將類別稍微分開),但與 EfficientNet 相比效果沒那麼好,類別間重疊的部分較多;圖 43、44 為對 Roboflow1 的訓練集、測試集進行分析;圖 45、46 為對 Roboflow2 的訓練集、測試集進行分析




圖 43




圖 44




圖 45




圖 46

4.2.2 ResNet

- 表 5 為使用 EfficientNet 模型分別對重建過後的 Roboflow1 及 Roboflow2 兩個資料集做訓練的 F1-Score 結果,相較於原始資料集,在 Roboflow2 的表現上重建後的資料集 F1-Score 都有略微提升。

	Stage 1	Stage 2	Stage 3	Stage 4	Accuracy	F1-Score
Roboflow1	0.19	0.34	0.38	0.3250	0.3300	0.3132
Roboflow2	0.88	0.70	0.52	0.77	0.7269	0.7193

表 5

- 模型的 Loss 與 Accuracy 趨勢圖如下,圖 47、48 為對 Roboflow1 的趨勢圖;圖 49、50 為對 Roboflow2 的趨勢圖




圖 47




圖 48




圖 49




圖 50

- 模型的權重圖如下,由此可發現我們的模型是健康的。圖 51、52 為對 Roboflow1 資料集的分析成果,圖 51 為整個模型的權重圖,圖 52 為對最後一層進行分析的結果;圖 53、54 為對 Roboflow2 資料集的分析成果,圖 53 為整個模型的權重圖,圖 54 為對最後一層進行分析的結果




圖 51




圖 52




圖 53




圖 54

- 下圖為訓練後再對資料進行 PCA 分析,可以看到相較於 Roboflow1, Roboflow2 具有較佳的成果(將類別稍微分開),但與 EfficientNet 相比效果沒那麼好,類別間重疊的部分較多;圖 55、56 為對 Roboflow1 的訓練集、測試集進行分析;圖 57、58 為對 Roboflow2 的訓練集、測試集進行分析




圖 55




圖 56




圖 57




圖 58

4.3 Ordinal Classification

- 由於我們發現使用一般分類時,準確率很難再提升,所以我們想找找是否有其他方法可以提升其準確率,因此嘗試了 ordinal classification,目的是希望能夠比較使用有序性分類是否效果會比一般分類更佳。
- 分別對 ResNet 及 EfficientNet 跑 Roboflow1 及 Roboflow2,分別訓練結果如下:

	Stage 1	Stage 2	Stage 3	Stage 4	Accuracy
--	---------	---------	---------	---------	----------

Roboflow1	0.42	0.10	0.15	0.34	0.31
Roboflow2	0.67	0.03	0.47	0.61	0.50

表 6. EfficientNet F1-Score

	Stage 1	Stage 2	Stage 3	Stage 4	Accuracy
Roboflow1	0.42	0.00	0.00	0.34	0.30
Roboflow2	0.57	0.00	0.00	0.57	0.48

表 7. ResNet F1-Score

- Accuracy 隨訓練過程變化如圖 59,可以看出 Accuracy 在 20 回合出現停滯,而在 70 回合左右突破停滯,Accuracy 有上升趨勢。




圖 59. Accuracy 折線圖

- loss 隨訓練過程變化如圖 60,能明顯看出來 Vaild 在 30 回合之後就沒有再下降的趨勢。




圖 60. Loss 折線圖

- 從混淆矩陣(圖 61)能看出來各級數的預測結果偏向往更嚴重方向來進行預測




圖 61.Ordinal 混淆矩陣

- 超參數調整項目: $\alpha_2(0.6)$ 、 $\eta(0.6)$ 、 $\text{optimizer_weight_decay}(5e-4)$ 、 $\text{lr}(1e-4)$
- 結果: 訓練結果顯示除了 EfficientNet 搭配 Roboflow2 以外, 幾乎都沒有訓練效果, 且不論是 EfficientNet 還是 ResNet, 都比一般分類時訓練成果還要更差, 因此 ordinal classification 在本研究中成效較差。

4.4 Multi-task

- 由於上述嘗試的方法, 表現都仍無法達到最理想, 所以希望可以藉由 Multi-task 中對於共用端(Encoder)所輸入特徵之梯度會受到所有訓練任務影響之特性, 去將原本的 1-4 級分類, 分為三種分類任務: 1-4 級原分類、嚴重度分類(1&2 為輕度, 3&4 為重度)、還有為了不忽略 3、4 級之區分的(1&2、3、4 級分類), 期望可以透過三個任務之間的互相影響, 幫助我們主要觀察的 1-4 級一般分類可以獲得最佳效果。
- 模型架構:

Encoder 由 EfficientNetb2 以及 Resnet50 為基底做特徵提取, 並調整為 1408 的輸入工三個 Decoder(分類任務)端使用, 最後藉由個分類端之 loss 值, 兩兩比對找出可以使 total_loss 最小之搭配, 並讓 total_loss 去修正前方共用任務的梯度。




圖 62.Multi-task 模型架構

- 模型訓練成果:

	Stage 1	Stage 2	Stage 3	Stage 4	Accuracy
Roboflow1	0.91	0.84	0.85	0.95	0.88
Roboflow2	0.25	0.34	0.12	0.15	0.23

表 8.EfficientNetb2 F1-score

	Stage 1	Stage 2	Stage 3	Stage 4	Accuracy
Roboflow1	0.93	0.84	0.80	0.90	0.86
Roboflow2	0.67	0.03	0.47	0.61	0.50

表 9.Resnet50 F1-score

○ 最佳結果之訓練過程折線圖：




圖 63.一般分類(1-4 級)




圖 64.嚴重度分類(1&2、3&4)




圖 65.3、4 級著重分類(1&2、3、4)

由圖 63-65 可以觀察到,在一般分類任務上的 loss 很早就停止下降,並且很早就 overfitting,為此我們後續將利用資料式視覺化的方式試著分析可能原因。

- 最佳模型之混淆矩陣(以主要觀察對象 1-4 級一般分類呈現)




圖 66

由圖 66 可以發現,藉由 multi-task 方法分類之結果較其他分類任務理想,錯誤也較集中在相近類別,沒有跨多級別的嚴重分類錯誤發生,但可能仍須調整任務項目使其相近級別的分類上更加敏感。

- 超參數調整:

	epochs / batch size	optimizer / lr / weight_decay	lr_scheduler/ step_size/ gamma	loss function	Loss(weight/ label_smoothing)
Normal Classification	20/16	Adam/0.0001/1e-4	StepLR/5/0.3	rossEntropyLoss	[1.0,1.0,1.0,1.0] / 0.0
Severity	20/16	Adam/0.0001/1e-4	StepLR/5/0.3	rossEntropyLoss	[1.0,1.0] / 0.0

Classification					
Stage 3&4 Classification	20/16	Adam/0.0001/1e-4	StepLR/5/0.3	rossEntropyLoss	[1.0,1.0,1.0] / 0.0

表 10

五、資料視覺化

5.1 濾波器激活視覺化

- 這個部份我們將 Multi-task 訓練完成以後,將濾波器可視化出來的結果,能夠從中看到模型在每一層當中的學習效果。
- 將濾波器視覺化的過程如圖四所示。




圖 67

- Multi-Task 模型架構
 - EfficientNetb2(backbone)
 - backbone[0][0] (初始卷積層) => efficientnet_blocks[0]
 - backbone[0][1] ~ backbone[0][7] => efficientnet_blocks[1]~[7]
 - MBConv(Mobile Inverted Bottleneck Convolution)
 - Conv2d(卷積)Norm(正規)Activation(激勵)
 - Squeeze(壓縮)Excitation(激勵)
 - backbone[0][8] (最終卷積層) => efficientnet_blocks[8]
 - NormalClassHead
 - OrdinalHead
 - ThreeHead
 - 可視化結果
 - 在最佳的權重之下,EfficientNetb2(圖 68)、EfficientNetb2+一般分類(圖 69)、EfficientNetb2+嚴重程度分類(圖 70)、EfficientNetb2+Stage1&2 及 Stage3/Stage4 分類(圖 71)的濾波器如下



圖 68.EfficientNetb2 濾波器



圖 69.EfficientNetb2+一般分類濾波器




圖 70.EfficientNetb2+嚴重程度分類濾波器




圖 71.EfficientNetb2+Stage1&2/Stage3/Stage4 分類濾波器

5.2 剪枝

- 為提升模型訓練速度並剔除冗餘的參數,我們嘗試對模型進行剪枝,我們大概將模型分為四大部分(SharedEfficientNetBackbone Parameters、NormalClassHead

Parameters、OrdinalHead Parameters 與 ThreeHead Parameters),表 11 為各部分的參數量:

	特徵提取共享層	NormalClassHead Parameters	OrdinalHead Parameters	ThreeHead Parameters
參數數量	7,700,994	724,484	723,458	723,971

表 11

- 約 78% 的參數都在特徵提取共享層的部分,因此我們針對此部分進行剪枝,嘗試剪枝比例 0%~50% 觀察在何種情況下可以達到準確率和參數量最為平衡的狀態,下圖為不同剪枝比例的準確率變化圖,由圖 72 可知,約剪枝 20% 參數量為最佳情況。




圖 72

5.3 分類關注區域

- 動機:

由於 Multi-task 在很早時就發現其 loss 無法再下,且在早期就有過擬合之現象發生,我們希望可以透過視覺化共用端任務最後輸出層也就是輸入個任務之特徵圖的視覺化分析,來看看模型的各分類上主要關注了甚麼特徵。

- 原理:

step1:

forward:抓取卷積核之輸出值(featuremap)

backward:取得最後分類輸出之 loss 倒傳遞計算後對特徵卷積輸出的 grad

step2:

將經過 1408 個特徵卷積和卷積而得的中間特徵輸出圖,去與 loss 計算而得到他們之間的 grad,並且,對 1408 張特徵圖中的每個像素之 grad 取平均,等於將 7*7 取平均而得 1408,目的是為了將其與特徵輸出圖中的值,做相乘而得該特徵圖中的值

對分類輸出的相關重要度,最後將所有圖加總的到特定位置之特徵總資訊對分類輸出的相關重要度。

step3:

-將 7*7 的特徵圖利用雙線性差值縮放到與原圖同樣大小,再對其依照像素值大小(=在分類上的重要度)給予連續顏色(jet 對應),以利於可視化上的直觀性(像素值越大越接近藍->紅中紅色那側顏色,代表越重要)。

- 成果(以最佳的模型展示):




圖 73.stage1




圖 74.stage2




圖 75.stage3




圖 76.stage4

● 結論:

由圖 73-76 的視覺化成果可以觀察到,模型在分類時的主要關注特徵,並沒有在我們所期望的傷口色彩變化區域上,並且我們也有觀察每個 Epoch 的關注區域變化,我們發現,對於每代訓練,在分類上的關注區域並沒有慢慢地集向同一區域,而是大幅變化,我們推測這可能也是使我們的 loss 沒有辦法突破更低點的原因。後續改善方向,我們希望可以藉由引入色彩注意力機,來讓模型可以更好的學習到相關特徵。

六、結果與討論

Model	Stage 1	Stage 2	Stage 3	Stage 4	Accuracy	Dataset
EfficientNet	0.91	0.83	0.80	0.91	0.8611	Roboflow 2
EfficientNet (Image reconstruction)	0.85	0.78	0.75	0.93	0.8241	Roboflow 2
EfficientNet (Ordinal)	0.67	0.03	0.47	0.61	0.50	Roboflow 2
EfficientNet (Multi-Task)	0.91	0.84	0.85	0.95	0.88	Roboflow 2

表 12.各模型最佳數據比較表

1. Multi-task 為本篇所有分類方法中,效果最佳者

- 由於 Multi-task 分類可以透過自訂訓練任務,來使訓練結果可以相互影響,不只關注單一種分類面相,可以有更全面的學習,因此可由表 12 發現,在本次訓練中相較於其他任務,Multi-task 獲得了較佳的結果。

2. Roboflow2(R2)的分類表現較 Roboflow1(R1)佳

- 原始資料集 R1 中會出現一些像是手術型傷口或者其他不屬於壓瘡傷口之物品,可能會導致資料集本身就小雜訊又過多,另外我們還有對資料集進行擴增,導致圖

片之間的相似度太高,模型沒辦法很好的學習特徵,導致學習效果不佳,因此容易出現過擬合問題,從而後面測試與驗證的泛化性不高。

3. Efficientnet 的分類表現較 Resnet 佳

- 因為 resnet 只對模型層數有更正,而 efficientnet 會對模型的深度、寬度、解析度進行同比例縮放,這使 efficientnet 可以處理更高解析度的照片,能保留更多細節特徵,這對於辨識上有明顯優勢。此外,efficientnet 和 resnet 所使用的激勵函數也不同,efficientnet 所使用的 swish 是一種平滑的非線性函數,能保留更多梯度訊號,而 resnet 的 relu 容易出現資訊損失的問題。

七、未來發展方向

- 我們起初發想的最終目標是希望能夠透過此專題實際幫助到居家照護者以及剛進入臨床的新進護理人員,目前我們的系統尚停留在模型辨識階段,主要完成了對傷口影像的分類。然而,未來我們期望能進一步將這些研究成果轉化為一個具體可用的工具,例如建置成一個網頁平台或行動裝置應用程式(APP),讓使用者能夠透過簡單的操作,如拍照上傳傷口圖片,便可快速獲得傷口分級的判斷結果。此外,若應用於醫療機構,我們亦希望系統能與院內的電子病歷或資料庫整合,不僅可即時呈現辨識結果,也有助於護理人員進行病歷記錄、傷口追蹤與後續照護,提升整體照護效率與品質。

八、資料來源

- [1]D. Bluestein and A. Javaheri, “Pressure ulcers: Prevention, evaluation, and management,” American Family Physician, vol. 78, no. 10, pp. 1186–1194, Nov. 2008.
- [2]Tan, M., & Le, Q. V. (2019). EfficientNet: Rethinking model scaling for convolutional neural networks. In Proceedings of the 36th International Conference on Machine Learning (pp. 6105–6114). PMLR. <https://arxiv.org/abs/1905.11946>
- [3]He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR) (pp. 770–778). IEEE. <https://arxiv.org/abs/1512.03385>
- [4]Wang, X., Xie, L., Dong, C., & Shan, Y. (2021). Real-ESRGAN: Training real-world blind super-resolution with pure synthetic data. arXiv preprint arXiv:2107.10833. <https://arxiv.org/abs/2107.10833>
- [5]Francisco B´erchez-Moreno, Rafael Ayll´on-Gavil´an, V´ictor M. Vargas, David Guijo-Rubio, C´esar Herv´as-Mart´inez, Juan C. Fern´andez, Pedro A. Guti´errez, ”dlordinal: a Python package for deep ordinal classification”,arXiv:2407.17163v3 [cs.LG] 10 Jan 2025
- [6]Sener, O., & Koltun, V. (2018). Multi-Task Learning as Multi-Objective Optimization. arXiv preprint arXiv:1810.04650. <https://arxiv.org/abs/1810.04650>
- [7]Olah, C., Mordvintsev, A., & Schubert, L. (2017). Feature visualization. Distill. <https://distill.pub/2017/feature-visualization>
- [8] AI Academy Taiwan, “利用 Feature Visualization 了解 CNN 到底在看什麼,” Medium, Apr. 8, 2020. [Online]. Available: <https://medium.com/ai-academy-taiwan/利用 feature-visualization-了解 cnn 到底在看什麼-40d36b347448>

[9]數學美, “Feature Visualization:讓 CNN 自己告訴你它在看什麼,” 數學美 MathPretty, Oct. 19, 2021. [Online]. Available: <https://mathpretty.com/10475.html>

[10]Leo Chiu(2019.4.5)使用 Grad-CAM 解釋卷積神經網路的分類依據. Medium.

<https://medium.com/%E6%89%8B%E5%AF%AB%E7%AD%86%E8%A8%98/grad-cam-introduction-d0e48eb64adb>

[11]Martin Huang(2022.6.15)可視化神經網路:Grad-CAM 小簡介 — 論文筆記(1)什麼是 Grad-CAM.

Medium.<https://martin12345m.medium.com/%E5%8F%AF%E8%A6%96%E5%8C%96%E7%A5%9E%E7%B6%93%E7%B6%B2%E8%B7%AF-grad-cam%E5%B0%8F%E7%B0%A1%E4%BB%8B-%E8%AB%96%E6%96%87%E7%AD%86%E8%A8%98-1-%E4%BB%80%E9%BA%BC%E6%98%AFgrad-cam-ee187d88e380>